

1. 从你的二阶展开看问题本质

你给的式子是

$$\Delta L = g^T \Delta \theta + \frac{1}{2} \Delta \theta^T H \Delta \theta$$

其中

- $g = \nabla L$
- $H = \nabla^2 L$ (Hessian)

梯度下降的更新是

$$\Delta \theta = -\eta g$$

代入得到

$$\Delta L = -\eta g^T g + \frac{1}{2} \eta^2 g^T H g$$

于是

$$\Delta L = -\eta \|g\|^2 + \frac{1}{2} \eta^2 g^T H g$$

关键点来了：

如果

$$\frac{1}{2} \eta^2 g^T H g > \eta \|g\|^2$$

那么

$$\Delta L > 0$$

loss 就会上升。

整理一下：

$$\eta > \frac{2\|g\|^2}{g^T H g}$$

这其实就是 **gradient descent stability condition**。

换句话说：

学习率超过了 curvature 允许的稳定范围。



2. 为什么 Adam 特别容易触发这个问题

Adam 更新:

$$\theta_{t+1} = \theta_t - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}$$

其中

- m_t : 一阶动量
- v_t : 梯度平方动量

Adam 的问题是:

(1) 有效 learning rate 会突然变大

当

$$\sqrt{v_t}$$

变小的时候

更新会变成

$$\Delta\theta \approx \eta \frac{g}{small}$$

step 会突然 爆炸。 [PyTorch Forums](#)

(2) curvature 很大的方向没有被抑制

Adam只用

$$diag(g^2)$$

近似 Hessian。

但真正的 curvature 是

$$H$$

如果

$$\lambda_{max}(H)$$

很大

就会进入 unstable regime。

最新研究甚至证明:

当 Adam 的预条件矩阵和 Hessian 的最大特征值组合超过稳定阈值时, 会触发 **loss spike**。 [arXiv](#)



3. 你现在的的问题

你现在的策略：

如果 $\text{loss increase} > 1e-6$
就 $\text{lr} \times 0.1$

问题是：

(1) 你是在 事后反应

loss spike 已经发生。

(2) epoch 太粗粒度

Adam instability 发生在 **iteration level**。

(3) spike 不是单次事件

Adam 有一种现象叫

loss spikes / sawtooth effect

loss 会持续震荡。 [arXiv](#)

所以你看到的：

loss持续上升

其实是 optimizer 进入 **unstable region**。

4. 实际研究中常用的解决方案

我按 从简单到研究级排序。

方案1（最常见）：Gradient Clipping

直接限制 step size

$$\|g\| \leq c$$

例如

```
Python
torch.nn.utils.clip_grad_norm_(model.parameters(), 1.0)
```

运行

作用：

限制

$$\Delta\theta$$

避免

$$\eta^2 g^T H g$$

项爆炸。

这是 工业界最常用解决方案。

方案2：AMSGrad

Adam 有已知收敛问题。

AMSGrad 修改为：

$$v_t = \max(v_{t-1}, v_t)$$

避免 denominator 变小。

论文：

On the Convergence of Adam and Beyond

方案3: 学习率 warmup + decay

不是根据 loss spike 调整。

而是:

warmup → plateau → decay



原因:

高 curvature region 一般在 early stage。

方案4: trust region / line search (最符合你这个二阶分析)

经典优化的解决方案:

限制

$$||\Delta\theta||$$

或保证

$$\Delta L < 0$$

例如

- Levenberg–Marquardt
- Trust Region Methods

思想:

不是固定 lr, 而是

$$\min_{\Delta\theta} g^T \Delta\theta + \frac{1}{2} \Delta\theta^T H \Delta\theta$$

subject to

$$||\Delta\theta|| < r$$

方案5（研究级）：Sharpness-Aware Minimization

SAM 做的是：

寻找

flat minima

而不是 sharp minima。 维基百科

sharp minima = Hessian eigenvalue大。

5. 我最推荐的解决方案（结合你的研究）

如果我是你，我会按这个顺序：

Step 1（必须）

加

gradient clipping



Step 2

换 optimizer

Adam → AdamW + AMSGrad



Step 3

加 scheduler

ReduceLROnPlateau



而不是自己写 rule。

Step 4（如果仍然有 spike）

计算

$||\Delta\theta||$



限制 step norm



6. 一个更深层的 insight (对你论文可能有用)

你现在观察到:


$$\frac{1}{2} \Delta \theta^T H \Delta \theta$$

主导。

这其实说明:

你处在 **sharp valley**。

loss surface 类似:



这种地方

gradient methods 会 **bounce**。 DigitalOcean

7. 一个我很好奇的问题 (很关键)

你的系统是:

HNODE + AFM force reconstruction

我想确认一件事:

你的 loss spike 是不是发生在

force network training阶段?

还是

mechanical parameter estimation阶段?

因为:

如果是 **parameter estimation**

那问题可能不是 optimizer。

而是

structural identifiability problem。

这个在 AFM reconstruction 里非常常见。

如果你愿意, 我可以:

- 帮你 从优化理论角度彻底解释这个现象
- 甚至帮你 设计一个专门适合 HNODE 的 optimizer strategy

(这个其实已经接近一篇 optimization paper 了)

📄 🌟 📌 🔄 ⋮ 🔗 来源